

Raspagem de dados visando análise de preços e promoções de smartphones

Felipe Candido;

¹FATEC ARARAS, Brasil, felipe.candido4@fatec.sp.gov.br

The growth of e-commerce platforms has generated a large volume of publicly available data that can be explored to extract valuable insights. This study aims to collect, preprocess, and analyze data related to smartphone products listed on the Mercado Livre platform using web scraping techniques.

The data collection process was performed using Python, with the support of libraries such as BeautifulSoup and Pandas, enabling the extraction of relevant attributes including price, previous price, product rating, discount percentage, seller information, and shipping conditions. A dataset with over 1,000 records was constructed, meeting the minimum requirements for data mining analysis.

Keywords – Web Scraping, Data Mining, E-commerce, ETL, Exploratory Data Analysis

I. INTRODUCTION (HEADING 1)

O avanço das tecnologias digitais e o crescimento do comércio eletrônico têm proporcionado uma grande disponibilidade de dados que podem ser explorados para a extração de conhecimento. Nesse contexto, plataformas de e-commerce como o Mercado Livre disponibiliza uma vasta quantidade de informações estruturadas e semi-estruturadas, possibilitando análises sobre comportamento de mercado e padrões de consumo.

Entre os diversos segmentos presentes nessas plataformas, o mercado de smartphones se destaca pela alta competitividade, grande variedade de produtos, ampla faixa de preços e constante aplicação de estratégias comerciais, como descontos, frete grátis e vendas por lojas oficiais. A análise desses fatores permite compreender melhor como diferentes atributos influenciam o posicionamento e a percepção de valor dos produtos.

Este trabalho tem como objetivo realizar a coleta, tratamento e análise exploratória de dados de smartphones disponíveis no Mercado Livre, utilizando técnicas de web scraping. A partir disso, busca-se estruturar uma base de dados consistente, aplicando as etapas iniciais do processo de KDD (Knowledge Discovery in Databases), com foco em pré-processamento e preparação dos dados.

Tópicos abordados

Mineração de Dados – Trabalho Prático (Fase 1) Coleta, Tratamento e Análise Exploratória de Dados via Web Scraping
Curso de Desenvolvimento de Software Multiplataforma– [Nome da Instituição]
Abril de 2026

A análise proposta concentra-se na identificação de relações entre atributos como preço, avaliação dos usuários, presença de descontos, tipo de vendedor e condições de envio. Para isso, foram definidas as seguintes questões de pesquisa:

CORRELAÇÕES DE DADOS

- | |
|---|
| <ul style="list-style-type: none">• <i>Produtos mais caros possuem melhores avaliações?</i> |
| <ul style="list-style-type: none">• <i>Lojas oficiais praticam preços mais elevados?</i> |
| <ul style="list-style-type: none">• <i>A presença de frete grátis influencia o preço?</i> |
| <ul style="list-style-type: none">• <i>Os descontos representam reduções reais ou estratégias de marketing?</i> |

Nas seções seguintes, são apresentados os conceitos teóricos utilizados, a metodologia aplicada na coleta e tratamento dos dados, os resultados obtidos e as conclusões do estudo.

II. FUNDAMENTAÇÃO TEÓRICA

O processo de descoberta de conhecimento em bases de dados, conhecido como KDD (Knowledge Discovery in Databases), consiste em um conjunto de etapas que visam extrair conhecimento útil a partir de grandes volumes de dados. Esse processo inclui seleção, pré-processamento, transformação, mineração e interpretação dos dados.

No contexto deste trabalho, destaca-se a etapa de coleta de dados por meio de web scraping, que consiste na extração automatizada de informações disponíveis em páginas web.

Essa técnica permite a obtenção de dados estruturados a partir de conteúdos originalmente apresentados em formato HTML.

Após a coleta, os dados passam por um processo de ETL (Extract, Transform, Load), no qual são extraídos, transformados e carregados em uma estrutura adequada para análise. A etapa de transformação envolve a limpeza dos dados, correção de inconsistências, tratamento de valores ausentes e padronização de formatos.

O pré-processamento dos dados é fundamental para garantir a qualidade das análises realizadas posteriormente, uma vez que dados inconsistentes ou incompletos podem comprometer os resultados. Dessa forma, esta etapa tem papel essencial dentro do processo de KDD, preparando os dados para futuras aplicações de técnicas de mineração.

III. METODOLOGIA

A coleta de dados foi realizada a partir do site Mercado Livre, utilizando a linguagem de programação Python em conjunto com as bibliotecas **requests**, **BeautifulSoup** e **pandas**.

O processo de scraping consistiu na navegação automatizada pelas páginas de listagem de smartphones, utilizando paginação para garantir a coleta de mais de 1.000 registros, conforme exigido pelo trabalho. Para cada produto, foram extraídos atributos relevantes, incluindo título, preço atual, preço anterior, avaliação, marca, presença de desconto, informações de frete e indicação de loja oficial.

Após a coleta, os dados foram submetidos a um processo de transformação, no qual foram realizadas as seguintes operações:

• Conversão de preços para formato numérico
• Extração de valores percentuais de desconto
• Padronização de campos categóricos

• Criação de variáveis derivadas (ex.: frete_gratis, item_desconto)
• Tratamento de valores nulos

Além disso, foram implementados mecanismos de controle para evitar requisições excessivas ao servidor, incluindo intervalos aleatórios entre as requisições e tratamento de possíveis falhas durante a coleta. Também foi realizada a validação dos dados coletados, garantindo que apenas registros válidos fossem armazenados na base final, evitando a inclusão de páginas vazias ou respostas bloqueadas pelo servidor.

O fluxo completo do processo ETL pode ser descrito em três etapas principais: (i) extração dos dados diretamente das páginas HTML do Mercado Livre, (ii) transformação dos dados para padronização e enriquecimento das informações, e (iii) carga dos dados em um banco SQLite para posterior análise. Esse processo garante a organização e integridade dos dados utilizados nas etapas seguintes do trabalho.

IV. RESULTADOS

Após a etapa de coleta dos dados, foi realizada uma análise inicial da base, identificando a presença significativa de valores nulos em diversos atributos. Observou-se que campos como preço antigo, avaliação, loja e frete apresentavam inconsistências, com destaque para o atributo frete, que possuía a maior quantidade de valores ausentes. Esses nulos estão relacionados à própria natureza dos dados coletados, uma vez que nem todos os anúncios apresentam informações completas na plataforma.

Durante o processo de pré-processamento, foram aplicadas técnicas de tratamento de dados ausentes. Os valores nulos do atributo preço antigo foram substituídos pelo preço atual do produto, assumindo que a ausência desse campo indica a inexistência de desconto. Já os valores ausentes de avaliação foram preenchidos utilizando a mediana da distribuição, reduzindo o impacto de valores extremos. Para atributos categóricos, como loja e frete, foram utilizadas categorias padrão ("Desconhecida" e "Não informado"), garantindo a consistência dos dados.

Após o tratamento, observou-se a eliminação total de valores nulos na base, com exceção do atributo derivado `faixa_preco`, que apresentou pequena quantidade residual de valores ausentes devido à limitação das faixas definidas. Essa melhoria na qualidade dos dados permitiu análises mais confiáveis e consistentes.

Além disso, foi realizado o tratamento de outliers com foco em valores de preço extremamente baixos. Foram removidos registros com preço inferior a R\$ 500, por não representarem adequadamente o mercado de smartphones analisado e possivelmente indicarem erros de coleta ou produtos fora do escopo (como acessórios ou anúncios inconsistentes). Essa filtragem contribuiu para uma distribuição de preços mais realista e coerente com o contexto do estudo.

Em relação à duplicidade de dados, optou-se por não remover registros duplicados na base principal, uma vez que diferentes anúncios de um mesmo produto podem representar variações relevantes, como loja, condições de venda e estratégias comerciais. No entanto, no contexto do dashboard analítico, foram aplicadas técnicas de remoção de duplicatas em visualizações específicas, como no ranking de melhores oportunidades, garantindo uma apresentação mais clara e evitando redundância de informações.

A base final resultante apresenta maior consistência, redução de ruídos e melhor representatividade do mercado, possibilitando a construção de análises exploratórias e visualizações que evidenciam padrões relevantes, como a relação entre preço, avaliação e estratégias de desconto adotadas pelos vendedores.

V. Conclusão

O desenvolvimento deste trabalho permitiu a aplicação prática das etapas iniciais do processo de descoberta de conhecimento em bases de dados (KDD), com foco na coleta, tratamento e preparação de dados provenientes de um ambiente real de e-commerce.

Durante a execução do projeto, foram enfrentados desafios relacionados à coleta de dados, especialmente devido a mecanismos de proteção contra automação presentes na plataforma analisada. Isso exigiu a adoção de estratégias para controle de requisições e validação dos dados coletados, reforçando a importância de práticas responsáveis no uso de técnicas de web scraping.

Os resultados obtidos demonstram que é possível construir uma base de dados consistente e adequada para análises exploratórias, permitindo identificar padrões relevantes no mercado de smartphones, como variações de preço, impacto de descontos e comportamento de avaliações.

Como limitações, destaca-se o fato de que os dados representam um recorte temporal específico, podendo variar ao longo do tempo, além da dependência da estrutura do site para a coleta das informações.

Como trabalhos futuros, propõe-se a utilização dessa base para o desenvolvimento de dashboards interativos e aplicação de técnicas mais avançadas de análise de dados, como clustering, detecção de outliers e modelos de recomendação, ampliando o potencial de extração de conhecimento a partir dos dados coletados.

VI. Referências

- [1] Mercado Livre. "Plataforma de E-commerce". Disponível em: <https://www.mercadolivre.com.br/>
- [2] Python Software Foundation. "Python Documentation". Disponível em: <https://docs.python.org/>
- [3] Requests. "Requests: HTTP for Humans". Disponível em: <https://requests.readthedocs.io/>
- [4] Richardson, L. "Beautiful Soup Documentation". Disponível em: <https://www.crummy.com/software/BeautifulSoup/>
- [5] Pandas Development Team. "Pandas Documentation". Disponível em: <https://pandas.pydata.org/>
- [6] Streamlit Inc. "Streamlit Documentation". Disponível em: <https://docs.streamlit.io/>
- [7] Plotly Technologies Inc. "Plotly Python Graphing Library". Disponível em: <https://plotly.com/python/>