

Análise do Mercado de Celulares no Mercado Livre: Dashboard Interativo e Classificação por Aprendizado de Máquina

Felipe Pelicari Candido
FATEC Araras / Desenvolvimento de Software Multiplataforma
felipepcandido@gmail.com

Brazilian e-commerce has grown significantly, with Mercado Livre consolidating itself as the main channel for buying and selling electronics. Understanding the dynamics of pricing, discounts, and consumer satisfaction is highly relevant for buyers, sellers, and market researchers alike. This paper is part of the Data Mining discipline and continues Phase 1, which involved a literature review, data source definition, web scraping collection, and dataset cleaning. In Phase 2, the same dataset is used to build an interactive analytical dashboard and apply a supervised machine learning technique. This study is guided by three analytical questions: (i) which stores concentrate the highest average prices and price variability; (ii) whether products with higher discount percentages originally had higher prices; and (iii) if it is possible to predict a smartphone's price range based on its characteristics.

I. INTRODUCTION (HEADING 1)

O comércio eletrônico brasileiro tem crescido de forma expressiva, com o Mercado Livre consolidando-se como principal canal de compra e venda de eletrônicos. Compreender a dinâmica de precificação, descontos e satisfação dos consumidores é relevante tanto para compradores quanto para vendedores e pesquisadores de mercado.

Este trabalho integra a disciplina de Mineração de Dados e dá continuidade à Fase 1, na qual foram realizados o levantamento bibliográfico, a definição da fonte, a coleta por web scraping e a limpeza do dataset. Na Fase 2, o mesmo dataset é utilizado para construção de um dashboard analítico e aplicação de aprendizado de máquina supervisionado.

O trabalho é guiado por três perguntas analíticas: (i) quais lojas concentram maiores preços médios e variabilidade; (ii) produtos com maior desconto tinham originalmente preços mais elevados; e (iii) é possível prever a faixa de preço de um celular a partir de suas características.

II. BASE DE DADOS

A. Origem e Coleta

Os dados foram obtidos do Mercado Livre (www.mercadolivre.com.br), categoria celulares e smartphones, via web scraping com Python (Requests e

BeautifulSoup), no período definido na Fase 1. A base não foi substituída; todos os registros são os mesmos coletados anteriormente.

B. Volume e Atributos

Após limpeza e remoção de duplicatas, o dataset conta com mais de 1.000 registros e oito atributos, atendendo aos requisitos mínimos (≥ 1.000 registros, 3 numéricos e 2 categóricos). A Tabela I descreve cada campo.

TABELA I
Atributos do Dataset

Campo Tipo	Descrição
<i>titulo</i> <i>Texto</i>	Nome do anúncio conforme publicado pelo vendedor
<i>preco</i> <i>Numérico</i>	Preço atual do produto no momento da coleta (R\$)
<i>preco_antigo</i> <i>Numérico</i>	Preço anterior ao desconto, usado como âncora (R\$)
<i>desconto_pct</i> <i>Numérico</i>	Percentual de redução entre preço antigo e atual (%)
<i>avaliacao</i> <i>Numérico</i>	Nota média dos compradores, escala 0–5
<i>loja</i> <i>Texto</i>	Nome do vendedor responsável pelo anúncio
<i>frete_gratis</i> <i>Binário</i>	1 = frete grátis incluso; 0 = frete cobrado à parte
<i>score</i> <i>Numérico</i>	Pontuação composta para ranking de oportunidades

III. PERGUNTAS ANALÍTICAS

Foram formuladas três perguntas analíticas com valor informativo real para o domínio, evitando trivialidades. São específicas, respondíveis com os dados disponíveis e endereçam aspectos distintos do mercado.

A. Enunciado

P1: Quais lojas concentram os maiores preços médios e maior variabilidade de preços no Mercado Livre?

P2: Produtos com maior percentual de desconto originalmente tinham preços mais elevados — os maiores descontos são aplicados sobre produtos premium?

P3: É possível prever se um celular terá preço acima da mediana com base em desconto, avaliação e loja?

B. Mapeamento Perguntas × Respostas

O mapeamento abaixo indica como cada pergunta é respondida — pelo dashboard, pela técnica de ML, ou por ambos.

P1 — Dashboard: *Sim* (box plot e barras com desvio padrão, Aba 2). ML: Não aplicável.

P2 — Dashboard: *Sim* (scatter desconto × preço antigo, box plot por faixa, correlação por loja, Aba 3). ML: Não aplicável.

P3 — Dashboard: *Parcialmente* (importância de features, Aba 4). ML: *Sim* (Random Forest Classifier, Acurácia ~70%, AUC ~0,75).

IV. DASHBOARD

A. Ferramenta e Ambiente

O dashboard foi desenvolvido em Python com Streamlit [1] e visualizações em Plotly [2]. Os dados são lidos de um banco SQLite via sqlite3 e pandas [5]. Execução: streamlit run dashboard2.py (celulares.db na mesma pasta).

B. Estrutura e Filtros

O dashboard tem cinco abas: (1) Visão Geral, (2) P1 — Preços por Loja, (3) P2 — Desconto × Preço Antigo, (4) P3 — Modelo ML e (5) Melhores Oportunidades. Filtros globais na sidebar afetam todas as abas: seleção de lojas, faixa de preço e condição de frete. Cada aba possui filtros locais adicionais.

C. Boas Práticas

Paleta consistente: âmbar (#F5A623) para barras e histogramas, azul escuro (#2C3E50) para referências, verde (#27AE60) para positivos e vermelho (#E74C3C) para negativos. Todos os gráficos têm títulos descritivos, eixos com unidades e legendas. Tipo de gráfico escolhido por tipo de dado: histograma para distribuições, box plot para dispersão entre grupos, scatter para relações contínuas e barras horizontais para rankings.

D. Descrição das Visualizações

As treze visualizações estão organizadas abaixo por aba, com seus filtros e o que revelam.

Aba 1 — Visão Geral

- **Histograma de preços:** mostra concentração entre R\$ 400–2.500, cauda longa para premium; filtros: n. de barras, sidebar global

- **Pizza — participação das lojas:** poucas lojas dominam o volume, mercado concentrado; filtro: sidebar global

- **Scatter preço × desconto × frete:** frete grátis não se concentra em faixa específica de desconto; filtro: sidebar global

Aba 2 — Pergunta 1

- **Box plot preços por loja:** grande dispersão em algumas lojas revela portfólio diversificado; filtros: qtd. mínima de anúncios e critério de ordenação

- **Barras: preço médio ± desvio + mediana:** mediana < média na maioria das lojas confirma assimetria positiva; mesmo filtro do box plot

Aba 3 — Pergunta 2

- **Scatter desconto × preço antigo:** correlação positiva moderada: produtos mais caros recebem descontos maiores; filtros: faixa de desconto, linha de tendência OLS

- **Box plot por faixa de desconto:** faixas acima de 30% concentram produtos com preço anterior mais alto; filtro: herdado

- **Barras horizontais: correlação por loja:** comportamento heterogêneo entre lojas; filtro: sidebar global

Aba 4 — Pergunta 3

- **KPIs do modelo (5 métricas):** acurácia ~70%, AUC ~0,75; modelo treinado no dataset completo

- **Matriz de confusão:** erros distribuídos simetricamente; sem viés marcante para uma classe

- **Curva ROC:** AUC de ~0,75 confirma boa capacidade discriminativa

- **Importância de features:** loja é o preditor principal, seguido por desconto; avaliação contribui pouco

Aba 5 — Melhores Oportunidades

- **Scatter oportunidades:** produtos com alto score combinam desconto elevado, boa avaliação e preço acessível; filtros: qtd., avaliação mínima, desconto mínimo

V. TÉCNICA DE APRENDIZADO DE MÁQUINA

A. Escolha e Justificativa

Foi aplicada classificação supervisionada com Random Forest [3] para responder à Pergunta 3. Justificativa: (i) robusto a outliers e distribuições assimétricas; (ii) lida com features mistas (numéricas e categóricas codificadas); (iii) dispensa normalização; (iv) fornece importância de features nativa, enriquecendo a interpretação.

B. Explicação Técnica

O Random Forest constrói um ensemble de árvores de decisão, cada uma treinada em subconjunto aleatório dos dados (bagging) e com subconjunto aleatório de features por nó. A predição final é por votação majoritária, reduzindo variância e aumentando generalização.

Variável alvo: `acima_mediana` (1 se preço > mediana; 0 caso contrário). Features: `desconto_pct`, `avaliacao` e `loja_enc` (LabelEncoder). Divisão: 80% treino / 20% teste com estratificação. Parâmetros: `n_estimators=100`, `max_depth=6`, `class_weight='balanced'`, `random_state=42`.

C. Resultados

A Tabela IV apresenta as métricas obtidas no conjunto de teste.

TABELA IV
Métricas de Avaliação — Random Forest

Métrica	Valor	Interpretação
Acurácia	~0,70	70% dos registros classificados corretamente
F1-Score	~0,70	Equilíbrio entre precisão e recall nas duas classes
Precisão	~0,71	71% dos preditos como acima da mediana eram corretos
Recall	~0,70	70% dos reais acima da mediana foram identificados
AUC-ROC	~0,75	Boa discriminação; supera baseline aleatório (0,5)

D. Análise Crítica

A `loja_enc` é a feature mais determinante, `desconto_pct` contribui secundariamente e `avaliacao` tem importância baixa — esperado pela concentração de notas na faixa 4,6–4,9. Acurácia de ~70% e AUC de ~0,75 superam o baseline aleatório, resultado satisfatório para o domínio. Limitações: codificação LabelEncoder atribui ordenação implícita às lojas (One-Hot Encoding melhoraria); ausência de features como marca e número de vendas; sensibilidade da variável alvo à composição do dataset.

VI. RESPOSTAS ÀS PERGUNTAS ANALÍTICAS

A. P1 — Preços por Loja

Dashboard: O box plot (Aba 2) evidencia lojas com preços medianos bem acima da média geral e desvio padrão elevado, indicando portfólios que vão de entrada a premium. O gráfico de barras com erro confirma a amplitude. O filtro de quantidade mínima de anúncios isola players representativos.

Conclusão: Existe heterogeneidade significativa entre lojas. Algumas atuam exclusivamente no segmento premium; outras cobrem toda a faixa. A mediana inferior à média

revela assimetria positiva causada por dispositivos de alto valor.

B. P2 — Desconto × Preço Antigo

Dashboard: O scatter da Aba 3, com linha de tendência OLS, revela correlação positiva moderada entre desconto (%) e preço antigo. O box plot por faixa confirma que produtos com desconto acima de 30% têm preços anteriores mais elevados. A análise por loja mostra comportamento heterogêneo.

Conclusão: Os maiores descontos são, em geral, aplicados sobre produtos mais caros — estratégia de ancoragem de preços. Isso não implica que o preço final seja mais acessível.

C. P3 — Previsão de Faixa de Preço

Dashboard: O gráfico de importância (Aba 4) mostra loja como preditor principal, seguido por desconto e avaliação.

ML: Random Forest atingiu acurácia ~70% e AUC-ROC ~0,75, com precisão e recall equilibrados (~0,70–0,71). A Curva ROC confirma desempenho superior ao baseline.

Conclusão: É possível prever com razoável confiabilidade a faixa de preço. O posicionamento da loja é o sinal mais forte — o vendedor determina a faixa de preço mais do que as características do produto em si.

VII. CONCLUSÃO

Este trabalho demonstrou que é possível extrair padrões informativos de dados coletados no Mercado Livre e comunicá-los por meio de dashboard interativo. As três perguntas foram respondidas com consistência entre evidências visuais e computacionais.

Principais aprendizados: diversidade de precificação entre lojas, relação entre ancoragem e descontos, e viabilidade de classificação automática de faixas de preço com Random Forest. A loja mostrou-se o fator mais determinante em ambas as análises.

Dificuldades: concentração de avaliações (baixo poder discriminativo), codificação de variáveis categóricas de alta cardinalidade e definição de variável alvo representativa. Próximos passos: clustering de perfis de lojas, novas features via scraping expandido e codificações alternativas para loja.

REFERÊNCIAS

- [1] Streamlit Inc., "Streamlit — The fastest way to build data apps," 2024. [Online]. Disponível: <https://streamlit.io>
- [2] Plotly Technologies Inc., "Plotly Python Open Source Graphing Library," 2024. [Online]. Disponível: <https://plotly.com/python/>
- [3] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [4] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *J. Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.

- [5] W. McKinney, "Data Structures for Statistical Computing in Python," Proc. 9th Python in Science Conf., pp. 51–56, 2010.
- [6] Mercado Livre, "Mercado Livre — Onde você compra, vende e paga," 2024. Disponível: <https://www.mercadolivre.com.br>
- [7] IEEE, "Manuscript Templates for Conference Proceedings," 2024. Disponível: <https://www.ieee.org/conferences/publishing/templates.html>